



Projet Final - Le Chant des Oiseaux

Romain Bertin
Maxime Rimbaud
144

Partie 1 - Visualisation du chant des oiseaux

Question 1

Les quatre enregistrements sont chargés avec `scipy.io.wavfile`. Lorsque le fichier est stéréo, on conserve uniquement le canal gauche. Le tableau ci-dessous résume les caractéristiques des signaux :

Oiseau	f_s (Hz)	Durée (s)	Type
Grand-duc d'Europe	48 000	14.82	Mono int16
Aigle royal	32 000	18.87	Mono int16
Loriot d'Europe	48 000	45.21	Mono int16
Rossignol philomène	44 100	8.33	Mono int16

Caractéristiques des fichiers audio.

Question 2

La Short-Time Fourier Transform (STFT) découpe le signal en segments de N_s échantillons qui se superposent à 50 % (i.e. le pas vaut $\text{hop} = N_s/2$). Pour le segment j , on extrait la portion


$$x_j = x \left[j \frac{N_s}{2} : j \frac{N_s}{2} + N_s \right]$$

et on lui applique la transformée de Fourier discrète. La matrice S est définie par :

$$S[i, j] = \text{TF} \left(x \left[j \cdot \frac{N_s}{2} : j \cdot \frac{N_s}{2} + N_s \right] \right)_i$$

Le script python réalisant la STFT se trouve dans le fichier `.py` de la partie 1 à la question 2. Le calcul effectue N_{seg} FFT de taille N_s , soit une complexité globale en $\mathcal{O}(N_{\text{seg}} \cdot N_s \log N_s)$.

Question 3




Spectrogramme $|S|$ du Grand-duc d'Europe avec $N_s = 2^{10} = 1024$, affiché sur la fenêtre temporelle $[12, 13.75]$ s et la gamme fréquentielle $[0, 10 \text{ kHz}]$.

Paramètres retenus.

- `t_min = 12.0 s`, `t_max = 13.75 s` : cette fenêtre contient plusieurs cris bien distincts, reproduisant l'exemple de l'énoncé.
- `freq_min = 0 Hz`, `freq_max = 10 000 Hz` : gamme imposée par le sujet.
- `v_max` fixé au 99^e percentile de $|S|$ sur la fenêtre affichée : cela évite que quelques valeurs extrêmes saturant la colormap et masquent les structures fines du signal.

Interprétation. On observe sur la figure ci-dessus plusieurs événements sonores périodiques (les cris du grand-duc), séparés par des silences. Chaque cri est un empilement d’harmoniques : une fondamentale vers 700 Hz, puis des harmoniques vers 1 400 Hz et 2 100 Hz, la troisième étant la plus intense. Chaque harmonique dessine un arc (légère montée puis descente de fréquence), reflétant la modulation propre au houhoulage du grand-duc. La fréquence dominante mesurée est d’environ 2 062 Hz, avec seulement 1,9 % de l’énergie $|S|^2$ au-dessus de 3 kHz (calcul sur la fenêtre affichée, entre 100 Hz et 10 kHz) : le grand-duc est un oiseau à spectre essentiellement grave et cela est cohérent avec les informations qu’on trouve sur le web affirmant que son cri est grave et puissant.

Question 4




Effet de $N_s \in \{64, 256, 1024, 4096\}$ sur le spectrogramme du Grand-duc d'Europe.

Interprétation. La figure ci-dessus illustre le compromis fondamental temps-fréquence inhérent à la STFT, directement lié au principe d’incertitude de Heisenberg :

- $N_s = 64$ (petit) : la fenêtre temporelle est courte ($64/48\,000 \approx 1,3$ ms), ce qui donne une très bonne résolution temporelle : on distingue bien l’enveloppe de chaque cri. En revanche, la résolution fréquentielle est faible ($\Delta f = f_s/N_s = 750$ Hz) : les structures spectrales fines sont noyées dans des bandes larges.
- $N_s = 4096$ (grand) : la fenêtre est longue (≈ 85 ms), ce qui donne une excellente résolution fréquentielle ($\Delta f \approx 12$ Hz) : les harmoniques et les modulations de fréquence sont très nettes. Mais les événements rapides s’étalent temporellement et les transitions deviennent floues.
- $N_s = 1024$: représente un bon compromis ($\Delta f \approx 47$ Hz, fenêtre de ≈ 21 ms), donnant des arcs bien définis tant en temps qu’en fréquence.
- $N_s = 256$: résolution intermédiaire, acceptable mais légèrement trop peu résolu en fréquence pour bien distinguer les structures spectrales du cri.

En résumé : augmenter N_s améliore la résolution fréquentielle mais dégrade la résolution temporelle, et vice-versa. Le choix $N_s = 2^{10}$ offre un bon équilibre pour les chants d’oiseaux étudiés ici.

Question 5



Comparaison entre l'implémentation maison et `scipy.signal.stft` pour le Grand-duc d'Europe ($N_s = 2^{10}$).

Les deux spectrogrammes de la figure ci-dessus présentent les mêmes structures globales (position temporelle et fréquentielle des cris, forme des arcs), ce qui valide notre implémentation.

Mais alors pourquoi scipy est plus “propre” ?

Notre implémentation effectue une FFT sur chaque segment rectangulaire brut, sans fenêtrage. Cela introduit un effet de fuite spectrale : les discontinuités aux bords du segment engendrent des lobes secondaires qui étalent l'énergie sur des fréquences voisines, dégradant la résolution effective.

En me renseignant sur `scipy.signal.stft` j'ai découvert qu'il applique par défaut une fenêtre de Hann avant la FFT :

$$w[n] = \frac{1}{2} \left(1 - \cos\left(\frac{2\pi n}{N_s - 1}\right) \right), \quad n = 0, \dots, N_s - 1$$


Cette fenêtre atténue progressivement les bords du segment vers zéro, réduisant fortement la fuite spectrale. Le résultat est un spectrogramme aux contours plus nets et aux lobes secondaires nettement atténués, au prix d'une légère réduction de la résolution fréquentielle principale.

Question 6

Pour chaque oiseau, `v_max` est fixé au 99^e percentile de $|S|$ sur la fenêtre choisie, afin de maximiser le contraste sans saturer la colormap. Les fenêtres temporelles sont choisies pour cibler des séquences de chant actif identifiées après inspection du signal entier.

Oiseau	t_min (s)	t_max (s)	v_max
Grand-duc d'Europe	12.0	13.75	99e percentile
Aigle royal	1.0	3.5	99e percentile
Loriot d'Europe	1.0	3.0	99e percentile
Rossignol philomène	1.0	3.5	99e percentile

Paramètres d'affichage par oiseau.



Spectrogrammes $|S|$ des quatre espèces sur $[0, 10 \text{ kHz}]$. Les fenêtres temporelles et les v_{max} sont choisis individuellement pour mettre en valeur les chants.

Grand-duc d'Europe (*Bubo bubo*). Le spectrogramme révèle une série de cris graves, modulés en fréquence, concentrés entre 700 et 2200 Hz. Chaque cri forme des arcs caractéristiques (montée puis descente de fréquence), séparés par des silences d'environ 0,25 s. L'énergie au-dessus de 3 kHz est très faible (1,9 %). À l'oreille, le chant est grave, profond et répétitif, cohérent avec le « houhoulage » nocturne de cet oiseau.

Aigle royal (*Aquila chrysaetos* — cri d'alarme). Le cri d'alarme de l'aigle présente une structure très différente : des éclats sonores brefs et intenses, dont les harmoniques s'étendent sur une large bande de fréquences (de 2 000 Hz jusqu'à 10 kHz). On note des raies verticales fines correspondant aux cris courts et percussifs, bien distincts des arcs lissés du grand-duc. L'essentiel de l'énergie reste autour de 2 kHz (8,9 % au-dessus de 3 kHz), mais ce sont ces harmoniques élevées qui rendent le cri perçant et saccadé à l'oreille. L'enregistrement contient aussi un bruit de fond très basse fréquence, visible en bas du spectrogramme, que l'on écarte du calcul.

Lorient d'Europe (*Oriolus oriolus*). Le loriot présente un chant mélodieux et sifflé, reconnaissable à une structure harmonique riche : on distingue une fréquence fondamentale entre 1 600 et 1 800 Hz et plusieurs harmoniques. Le chant évolue de façon continue, avec des glissements fréquentiels progressifs, signature du sifflement fluide caractéristique du loriot. L'énergie est presque entièrement portée par la fondamentale : seulement 1,3 % se trouve au-dessus de 3 kHz.

Rossignol philomène (*Luscinia megarhynchos*). Le rossignol se distingue par la richesse et la complexité de son chant : le spectrogramme montre une grande densité de structures temps-fréquence, avec une énergie significative sur toute la gamme 2 000–8 000 Hz (95,1 % de l'énergie au-dessus de 3 kHz). Les trilles rapides et les variations mélodiques rapides produisent des motifs très fragmentés et variés. C'est l'oiseau au chant le plus aigu et le plus varié des quatre, ce que l'on perçoit clairement à l'écoute.

Oiseau	f_{dom} (Hz)	Énergie >3 kHz	Structure temporelle
Grand-duc	~2 062	1,9 %	Cris discrets, arcs, lents
Aigle royal	~1 938	8,9 %	Cris courts, percussifs
Loriot	~1 828	1,3 %	Sifflements longs, harmoniques
Rossignol	~4 479	95,1 %	Trilles rapides, très varié

Comparaison spectrale des quatre oiseaux. La fréquence dominante et la part d'énergie sont calculées à partir de $|S|^2$, sur la fenêtre temporelle affichée et dans la bande [100 Hz, 10 kHz].

Ces différences de signature temps-fréquence rendent les espèces très discriminables visuellement, et motivent l'utilisation de la STFT comme vecteur de descripteurs pour une identification automatique (Partie 2).

Conclusion de la partie 1

Nous avons implémenté la STFT à partir de numpy. Le spectrogramme obtenu constitue une représentation temps-fréquence riche qui met en évidence les signatures acoustiques propres à chaque espèce : fréquence dominante, richesse harmonique, structure temporelle (discret vs. continu, lent vs. rapide). Le choix de $N_s = 2^{10}$ offre un bon compromis résolution temps-fréquence pour les signaux étudiés. L'utilisation d'une fenêtre de Hann (comme dans `scipy.signal.stft`) permettrait de réduire la fuite spectrale et d'obtenir des spectrogrammes encore plus nets.

Utilisation de l'IA dans la partie 1

J'ai utilisé l'IA Claude dans la partie 1 pour bien afficher mes figures dans un style similaire à celui du rapport. C'est également avec Claude que j'ai découvert le fonctionnement de `scipy.signal.stft`.

Partie 2 - Identification automatique d'oiseaux

Questions 1 & 2

Les 30 enregistrements `sample_0.wav` à `sample_29.wav` sont chargés via une boucle. Les fichiers stéréo sont réduits au canal gauche et les données sont converties en float64 pour les calculs numériques.

Pour chaque enregistrement i , on construit un vecteur de descripteurs x_i selon la procédure décrite par l'équation (2) du sujet :

1. STFT du signal avec `scipy.signal.stft` ($N_s = 1024$, recouvrement 50 %, fenêtre de Hann) $\rightarrow$ amplitude $|A(f, t)|$ (shape : $n_f \times N_t$)
2. Moyenne temporelle :

$$\tilde{s}_{i,j} = \frac{1}{N_t} \sum_{k=1}^{N_t} |A(f_j, t_k)|$$

On obtient un spectre moyen $\tilde{s}_i$ de dimension n_f .

3. Sélection fréquentielle : on conserve uniquement les composantes dans la bande [200, 6000] Hz, qui concentre l'essentiel de l'information bioacoustique pour ces espèces et exclut le bruit basse fréquence (bruits de vent, vibrations) et les artefacts haute fréquence.
4. Normalisation :

$$x_i = \frac{\tilde{s}_i}{\text{std}(\tilde{s}_i)}$$

Cette normalisation individuelle ramène tous les descripteurs à une variance unitaire, rendant la comparaison inter-enregistrements indépendante du volume sonore absolu.

Les 30 vecteurs $x_i \in \mathbb{R}^{n_f}$ sont assemblés en une matrice $A \in \mathbb{R}^{30 \times n_f}$ (une ligne par échantillon).


La PCA est réalisée manuellement via la décomposition en valeurs singulières (SVD). Pour une matrice centrée $\tilde{A}$:

$$\tilde{A} = U \Sigma V^\top$$

Les colonnes de V sont les vecteurs propres (axes principaux), les valeurs propres sont $\lambda_k = \sigma_k^2$, et les scores (coordonnées des individus dans l'espace PCA) sont donnés par $\hat{A}V$.

Faut-il normer la PCA ? Réponse : non, on ne réduit pas. Les variables de la matrice A sont les composantes fréquentielles du spectre moyen. Elles sont toutes de même nature et exprimées dans la même unité, et chaque enregistrement (chaque ligne de A) a déjà été normalisé par son propre écart-type à l'étape précédente (équation 2), ce qui rend les lignes comparables entre elles. Réduire en plus chaque variable (division par la std des colonnes de A) donnerait le même poids à toutes les fréquences, y compris à celles qui ne contiennent presque que du bruit, et nuirait à la discrimination.

On centre néanmoins systématiquement A avant la SVD, car c'est une condition nécessaire pour que la décomposition soit équivalente à la diagonalisation de la matrice de covariance.




On observe une décroissance rapide des valeurs propres : PC1 porte 44,1 % de l'inertie et PC2 18,4 %, soit 62,5 % à elles deux, avec un coude net à PC3 (8,0 %). Ce profil est cohérent avec une situation où trois groupes bien séparés existent dans les données : deux directions suffisent à séparer trois espèces, et la structure de la matrice de covariance est dominée par ces deux directions principales.


Les composantes suivantes (PC3, PC4, ...) ont chacune un taux d'inertie nettement plus faible (moins de 5 % à partir de PC4) et décroissent lentement : il faut neuf composantes pour dépasser 90 % de l'inertie. Elles correspondent surtout à des variations intra-espèces (variabilité individuelle des enregistrements, bruit).

Question 3

Classification des échantillons



La figure ci-dessus montre la projection des 30 enregistrements dans le plan formé par les deux premières composantes principales. Les trois points de référence (échantillons 0, 1, 2) permettent d'ancrer l'identification des groupes. On observe clairement trois groupes bien séparés, correspondant chacun à une espèce. Les points de référence (échantillon_0 = Merle noir, échantillon_1 = Rouge-gorge, échantillon_2 = Corneille) permettent d'identifier quel groupe correspond à quelle espèce.




Classification finale des 30 échantillons : chaque point est coloré selon l'espèce attribuée par proximité au point de référence dans l'espace (PC1, PC2).

Chaque échantillon inconnu est attribué à l'espèce dont le point de référence est le plus proche dans le plan PC1-PC2. Le tableau ci-dessous présente le résultat complet.


Sample	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	
Merle noir	X				X		X	X		X	X		X	X	X		X			X		X									
Rouge-gorge		X		X		X			X															X	X	X		X	X	X	
Corneille			X									X				X		X	X		X					X					X

Tableau d'identification des 30 échantillons. Merle noir : {0, 4, 6, 7, 9, 10, 12, 13, 14, 16, 19, 21} ; Rouge-gorge : {1, 3, 5, 8, 22, 23, 24, 26, 27, 28} ; Corneille : {2, 11, 15, 17, 18, 20, 25, 29}.

Interprétation des vecteurs propres



Vecteurs propres des composantes PC1 et PC2, représentés en fonction de la fréquence.



Spectres moyens normalisés des trois espèces. Les différences de forme spectrale expliquent la séparation opérée par la PCA.

Comment la PCA sépare-t-elle les trois espèces ? La PCA trouve les directions de l'espace fréquentiel qui maximisent la variance inter-individus. En regardant les deux figures ci-dessus, on peut formuler l'interprétation suivante :

PC1 — contraste médium/aigu. Le premier vecteur propre est négatif entre 1 000 et 2 700 Hz (minimum vers 2 000 Hz) et positif entre 3 000 et 4 500 Hz (maximum vers 3 750 Hz). Ce contraste permet de discriminer :

- le Rouge-gorge, dont le spectre moyen est concentré entre 3 000 et 4 100 Hz (pic vers 3 750 Hz), exactement là où le vecteur propre est maximal ;
- la Corneille et le Merle noir, dont l'énergie se situe plus bas, en dessous de 2 700 Hz.

Le Rouge-gorge se retrouve ainsi seul à l'extrémité positive de l'axe PC1 (coordonnée moyenne de +9,2), tandis que la Corneille et le Merle sont regroupés du côté négatif (−6,3 et −3,5).

PC2 — position du pic dans le médium. Le second vecteur propre capture une variation orthogonale à PC1 : il est positif entre 1 000 et 1 900 Hz (maximum vers 1 300 Hz) et négatif entre 2 000 et 2 800 Hz (minimum vers 2 350 Hz). Il sépare donc la Corneille du Merle noir. Le cri de la Corneille, plus grave, a un spectre moyen large qui culmine vers 1 800 Hz et s'étend dès 1 200 Hz : elle se place du côté positif de PC2 (+5,5 en moyenne). Le chant du Merle noir présente un pic plus étroit centré sur 2 350 Hz, à l'endroit précis où le vecteur propre est minimal : il se place du côté négatif (−4,5). Le Rouge-gorge, dont le spectre est presque nul dans cette bande, reste proche de zéro sur cet axe.

Ainsi la PCA réussit à séparer les trois espèces parce que leurs signatures spectrales moyennes sont suffisamment distinctes et stables d'un enregistrement à l'autre. Autrement dit, la variabilité inter-espèces (différences de forme spectrale entre Merle, Rouge-gorge et Corneille) est nettement supérieure à la variabilité intra-espèce (variations d'un enregistrement à l'autre pour la même espèce). C'est ce que traduit la domination de PC1 et PC2 dans l'éboulis des valeurs propres : ces deux axes captent avant tout la structure liée aux espèces, et non le bruit de mesure.

En résumé, le spectre moyen normalisé constitue un descripteur robuste et compact de l'identité acoustique d'une espèce, et la PCA révèle automatiquement les dimensions fréquentielles les plus discriminantes.

Utilisation de l'IA dans la partie 2

À nouveau j'ai utilisé Claude AI pour avoir de belles figures et également avant de commencer cette partie pour me réexpliquer les principes de la PCA.

Conclusion générale

Nous avons mis en œuvre un protocole complet d'identification automatique d'oiseaux basée sur la représentation temps-fréquence et l'analyse en composantes principales :

1. La STFT transforme chaque enregistrement audio en un spectrogramme bidimensionnel temps-fréquence.
2. La moyenne temporelle du spectrogramme produit un spectre moyen compact, représentatif de la signature acoustique de l'espèce dans l'enregistrement.
3. La normalisation individuelle (division par la std) rend la comparaison indépendante du volume d'enregistrement.
4. La PCA non normée (les descripteurs étant déjà sur des échelles comparables) révèle une structure en trois groupes nets dans l'espace des deux premières composantes, qui concentrent 62,5 % de la variance totale.
5. L'attribution par plus proche voisin dans l'espace PC1–PC2, en s'appuyant sur les trois enregistrements de référence connus, permet de classer automatiquement les 27 échantillons restants.

Cette approche est simple, interprétable et efficace pour des espèces aux profils spectraux bien distincts. Ses limites apparaîtraient sans doute avec des espèces acoustiquement proches, ou dans des conditions d'enregistrement très bruitées.